

# Simulering og eksperimentel modelbestemmelse, 5

Klaus Trangbæk

`ktr@es.aau.dk`

Automation & Control

Aalborg University

Denmark

# Dagens program

- Frekvens-domæne
  - Tids-domæne fit i frekvens-domænet
  - Parameter fit i frekvens-domænet

# Dagens program

- Frekvens-domæne
  - Tids-domæne fit i frekvens-domænet
  - Parameter fit i frekvens-domænet
- Praktiske forhold
  - Målinger og offset
  - DC-motor eksempel

# Dagens program

- Frekvens-domæne
  - Tids-domæne fit i frekvens-domænet
  - Parameter fit i frekvens-domænet
- Praktiske forhold
  - Målinger og offset
  - DC-motor eksempel
- Resume af kurset

# Frekvens-domæne

Modelfejlen i tids-domænet (**støj ignoreret**):

$$\epsilon(k, \theta) = y(k) - y_m(k, \theta) = (G_0(q) - G(k, \theta))u(k)$$

# Frekvens-domæne

Modelfejlen i tids-domænet (**støj ignoreret**):

$$\epsilon(k, \theta) = y(k) - y_m(k, \theta) = (G_0(q) - G(k, \theta))u(k)$$

Diskret Fouriertransformation af endeligt signal:

$$U_N(\omega) = \frac{1}{\sqrt{N}} \sum_{k=1}^N u(k) e^{-j\omega k}$$

# Frekvens-domæne

Modelfejlen i tids-domænet (**støj ignoreret**):

$$\epsilon(k, \theta) = y(k) - y_m(k, \theta) = (G_0(q) - G(k, \theta))u(k)$$

Diskret Fouriertransformation af endeligt signal:

$$U_N(\omega) = \frac{1}{\sqrt{N}} \sum_{k=1}^N u(k) e^{-j\omega k}$$

og den inverse DFT:

$$u(k) = \frac{1}{\sqrt{N}} \sum_{l=1}^N U_N(\omega_l) e^{j\omega_l k}$$

hvor  $\omega_l = \frac{2\pi l}{N}$ .

# Frekvens-domæne

Parsevals lighed:

$$\sum_{k=1}^N u^2(k) = \sum_{l=1}^N |U_N(\omega_l)|^2$$



# Frekvens-domæne

Parsevals lighed:

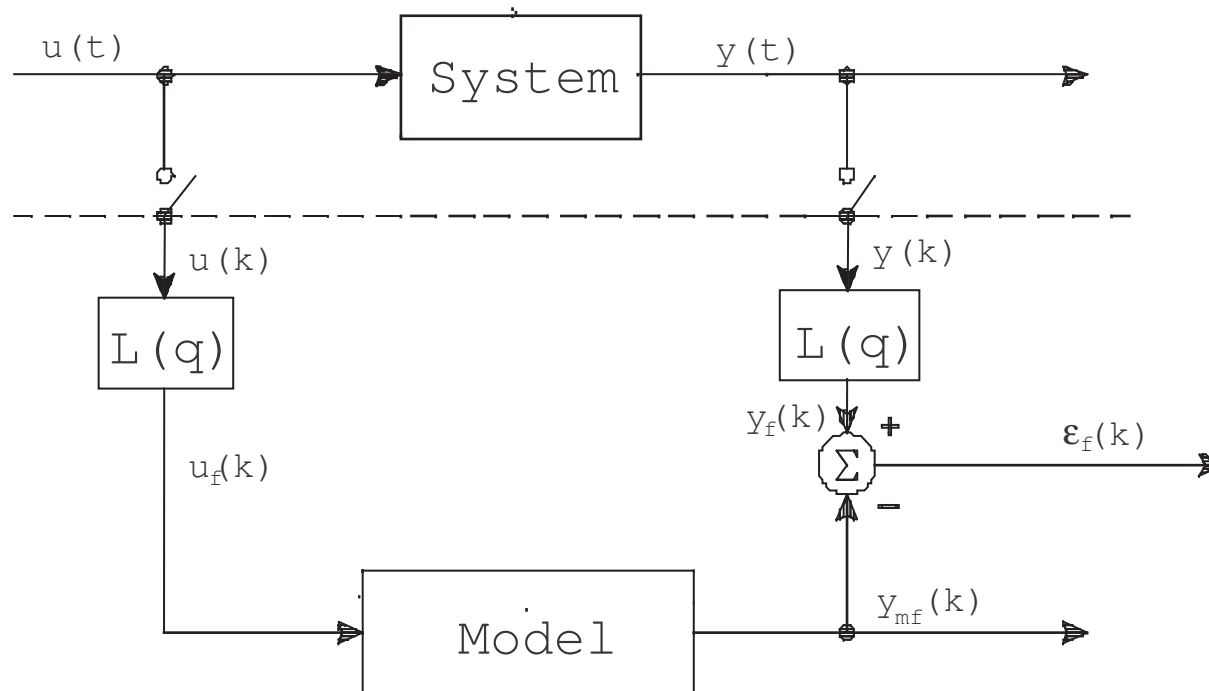
$$\sum_{k=1}^N u^2(k) = \sum_{l=1}^N |U_N(\omega_l)|^2$$

Performancefunktion tids  $\rightarrow$  frekvens-domæne

$$\begin{aligned} P_N(\theta) &= \frac{1}{2N} \sum_{k=1}^N \epsilon^2(k, \theta) = \frac{1}{2N} \sum_{k=1}^N |E_N(\frac{2\pi l}{N})|^2 \\ &= \frac{1}{2N} \sum_{k=1}^N |G_0(\omega_l) - G(\omega_l, \theta)|^2 |U_N(\omega_l)|^2 \end{aligned}$$

# Prefiltre

Prefiltre er digitale filtre på input og output signalerne  
Lineært system:




$\epsilon_f(k) = L(q)\epsilon(k)$ , dvs. ekstra vægtning  $L(q)$ .

Samlet vægtning:  $Q(\omega) = |L(\omega)|^2 |U_N(\omega)|^2$

# Prefiltre

Prefiltre er digitale filtre på input og output signalerne  
Ulineær model:



$\epsilon_f(k) = L(q)\epsilon(k)$ , dvs. ekstra vægtning  $L(q)$ .

Samlet vægtning:  $Q(\omega) = |L(\omega)|^2 |U_N(\omega)|^2$

# Parameter fit i frekvens-domænet

Modelparametrene kan bestemmes i frekvens-domænet, når der er målt frekvensrespons for systemet.

Performancefunktion:

$$P_f(\theta) = \frac{1}{2N} \sum_{k=1}^N |G_{0f}(j\omega_k) - G_f(j\omega_k, \theta)|^2$$

# Parameter fit i frekvens-domænet

Modelparametrene kan bestemmes i frekvens-domænet, når der er målt frekvensrespons for systemet.

Performancefunktion:


$$P_f(\theta) = \frac{1}{2N} \sum_{k=1}^N |G_{0f}(j\omega_k) - G_f(j\omega_k, \theta)|^2$$

Igen kan frekvensvægtning opnås ved at vælge forskellig input amplitude.

Reel- og imaginærdel behandles på samme måde som to output i tids-domænet.


# Praktiske forhold ved eksperimenter

Måleopstilling for DC-motor:



# Praktiske forhold ved eksperimenter

Måleopstilling for DC-motor:




Vær omhyggelig med jordinger (stelforbindelser)!

Husk: at kompensere for  $i \cdot R_m$  i  $u$ .

# Praktiske forhold ved eksperimenter

Fjernelse af offset: Lad input starte med et antal nuller, fx. 10



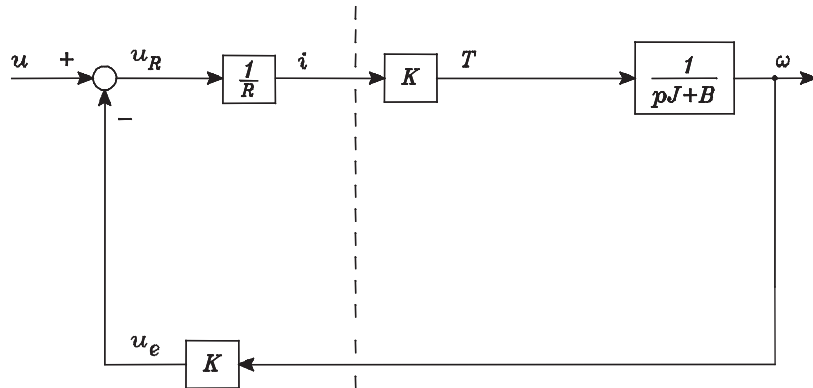
$$u = u - \text{mean}(u(1 : 10))$$

$$y = y - \text{mean}(y(1 : 10))$$

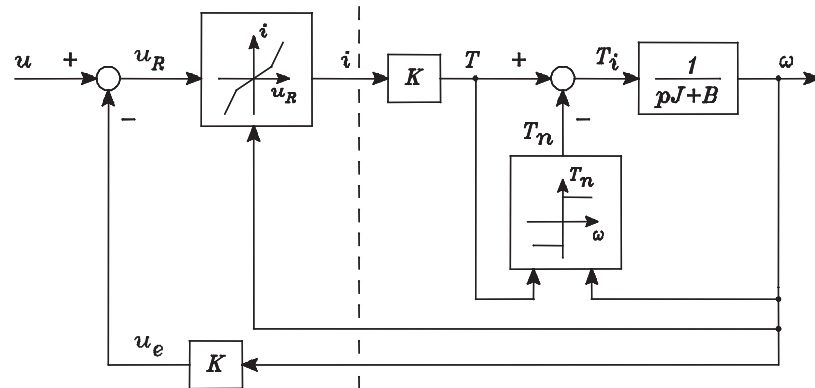


# DC-motor demo

Lineær model:



Ulineær model:




- Virkelige måledata:
- Først lineær model:
- Dernæst ulineær model:

`no = '8'`

`process = 'dcml'`

`process = 'dcmn'`



# Kursusoversigt

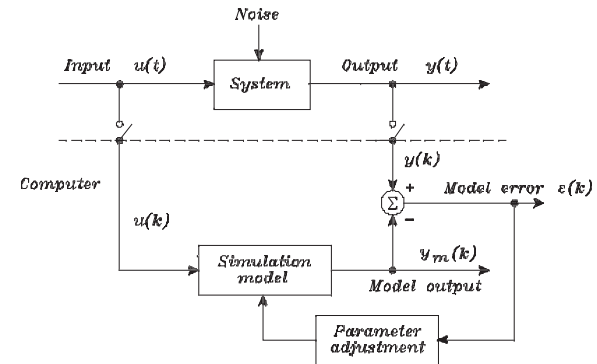
1. Introduktion, metode og procedure for eksperimentel modelbestemmelse, Grafisk modeltilpasning, System identifikation
2. Modelling, modelbeskrivelse og simulering
3. Senstools til parameterestimering
4. Parameternøjagtighed og følsomhed, Design af inputsignaler
5. Frekvensdomænet, Praktiske forhold

# Procedure for eksperimentel modellering

- **Bestemmelse af modelstruktur:** Modelstrukturen er bestemt af basal fysisk indsigt og empiriske overvejelser. En “**simuleringsmodel**” konstrueres.
- **Eksperiment design:** Specielt vigtigt er et “**godt**” **inputsignal**.
- **Eksperiment:** Systemet exciteres med inputsignalet og overensstemmende værdier af input- og outputsignaler samples og gemmes.
- **Parameter-estimation:** Simulationsmodellens **parametre justeres** til minimum afvigelse mellem det samlede system output og modellen.
- **Modelvalidering:** Korrektheden af **modelstrukturen** og nøjagtigheden af **parameter-estimerne** kontrolleres.

# Systemidentifikation

- Det fundamentale princip er:



- Det konverterer parametertilpasningsproblemet til minimering af Performancefunktionen:

$$P(\theta) = \frac{1}{2N} \sum_{k=1}^N \varepsilon^2(k, \theta)$$

- Dette kan gøres med Gauss-Newton metoden.
- Men der kræves en simuleringsmodel.

# Modeller og modellering: koncepter

## Definition:

**Model:** en *repræsentation* – i en brugbar form – af de *essentielle dele* af et system.

## Definition:

**Systemidentifikation:** *Udvikle matematisk model af dynamisk system baseret på observerede data fra systemet:*

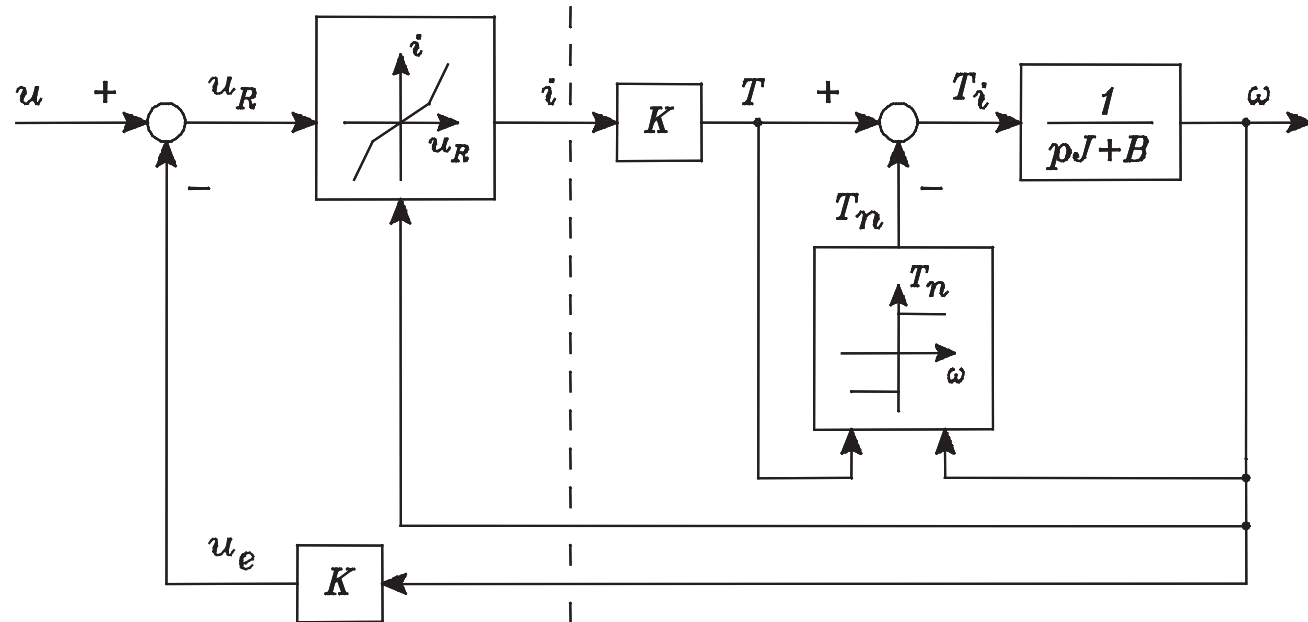
- *Mange måledata er indsamlet som samplede værdier af input og output*
- *En computer anvendes til behandling af data*
- *Model parametre estimeres ved minimering af et fejlkriterie*

# Matematiske Modeller

Model beskrivelser:

- Overføringsfunktion
- Tilstandsbeskrivelse
- Blok-diagram

DC-motor:



# Diskretiseringsmetoder

Navn	Algoritme	Karakteristik
Forward Euler	$s \rightarrow \frac{z - 1}{T}$	$x'(t)$ konstant over perioden
Tustin (Bilineær transformation)	$s \rightarrow \frac{2}{T} \frac{z - 1}{z + 1}$	$x'(t)$ variere lin. over perioden
Step invariant (ZOH ækvivalent)	$G_d(z) = (1 - z^{-1}) Z\left\{\frac{1}{s} G(s)\right\}$	$u(t)$ konstant over perioden
Ramp invariant (Tr H ækvivalent)	$G_d(z) = \frac{(1 - z^{-1})^2}{z^{-1} T} Z\left\{\frac{1}{s^2} G(s)\right\}$	$u(t)$ variere lin. over perioden
Pole-Zero mapping	$z_0 = e^{s_0 T}$	

# SENSTOOLS til parameter-estimation

- **Senstools** er en samling af Matlab programmer, der implementerer følsomhedsmetoden for **direkte parameter-estimation**, **eksperiment-design** og **model-validering**.
- Programmerne kan fordelagtigt organiseres som en **Matlab Toolbox**.
- Alt hvad brugeren behøver at programmere er **simulerings programmet for den specifikke proces**.
- Programmerne er organiseret som main programmer (script filer), der kalder underprogrammer (funktioner) og bruger data (mat filer).



# Procedure for parameter-estimation

For en proces med navn `xxx`:

1. **Opret simuleringsprogrammet** som en Matlab funktion: `y = simxxx.m`
2. **Gem de målte data** `t`, `u` og `y`: `save measxxx t u y`
3. **Indtast nødvendige programdata**, dette kan gøres på tre forskellige måder.
4. **Kør** `mainest.m` for parameter-estimation.

# Modelverifikation

En nøjagtig model forudsætter:

- God overensstemmelse mellem system og model output beskrevet ved

- Normed root mean output error:

$$errn = \sqrt{\frac{\sum_{k=1}^N (y(k) - y_m(k, \theta_N))^2}{\sum_{k=1}^N y^2(k)}}$$

- Plot af system og model output
- Gode parameterfølsomhedsmål
- Evaluering baseret på fysisk indsigt og fornuft

# Parameterfølsomhed

Parameterafhængigt bidrag på outputfejlen:

$$\epsilon_p(k, \theta) = y_m(k, \theta) - y_m(k, \theta_N) \approx \psi^\top(k, \theta_N)(\theta - \theta_N)$$

Parameterfølsomhed m.h.t. den  $i$ 'te parameter  $\theta_i$ :

$$S_i = \frac{\partial \epsilon_{p,RMSn}}{\partial \theta_{ri}} = \sqrt{h_{rni i}} \quad \left( = \{ \tilde{H}_{rn} \}_{ii} \right)$$

# Følsomhedsellipsoide

Disse karakteristiske mål er de mest beskrivende, specielt for flere end 2 parametre:

$S_{\min}$  minimum følsomhed, reciprok af major half axis  
– så stor som muligt

$S_i \min$  minimum følsomhed af  $\theta_i$  – så stor som muligt

$R = \frac{S_{\max}}{S_{\min}}$  forhold mellem max. og min. følsomhed i  
vilkårlig retning – så tæt på 1 som muligt

$R_i = \frac{S_i}{S_i \min}$  forhold mellem følsomhed af  $\theta_i$  alene og min.  
følsomhed af  $\theta_i$  – så tæt på 1 som muligt.  
 $R_i \gg 1$  indikerer at to eller flere parametre er  
korrollerede

# Parameternejagtighed

Parameterfejl kan skyldes to ting:

- Stokastisk parameter-usikkerhed forårsaget af støj
- Deterministisk fejl forårsaget af fejl i modelstrukturen (undermodellering)

# Inputsignal-design

- En procedure for design af et optimalt inputsignal blandt en given klasse af signaler.
- For lineære systemer var signalklassen firkantsignaler.
- For ulineære systemer var signalklassen firkant-rampe signaler.
- Signalet med grundfrekvens og amplitude fordeling der minimerer følsomhedsforholdet  $R$  er det optimale signal.
- I mange tilfælde er sund fornuft og erfaring tilstrækkeligt til at bestemme et godt inputsignal.

# Frekvens-domæne betragtninger

Et mindste kvadrater fit i tids-domænet er lig med et vægtet mindste kvadraters fit af frekvens funktionen.

Frekvensvægtningen er

$$Q(\omega) = |U_N(\omega)|^2$$

dvs. bedste fit er i frekvensområdet, hvor effekten i inputsignalet er høj.

Prefiltre kan anvendes til at ændre frekvensvægtningen.

# Afsluttende bemærkninger

- Senstools er oplagt at bruge i jeres 6. semester projekt.
- Vær opfindsomme mht. målinger, hvis systemet er ustabilt (vend opstillingen på hovedet, kør baglæns, luk sløjfen . . . )
- Der findes andre minimeringsmetoder end Gauss-Newton fx. Nelder-Mead simplex algortihm, der ikke anvender gradient information explicit.